先写 200 组词对能提升回答质量吗？

——对一项 240 对盲评实验的独立复算与再分析

作者姓名[1]

[1] 单位名称，城市邮编

email@example.com

摘要

在问题前加一句“先输出 200 组两词短语，再从中获得灵感”，是中文大模型社区流行的一种“灵感注入”式提示。本文对一个公开实验的 240 对盲评数据做独立复算与再分析。该实验覆盖 6 个开放式任务、2 个生成模型、2 个评委，每个“任务 × 条件”单元重复 10 次。复算显示：直接回答在 224/240 对中获胜（93.3%，任务聚类 bootstrap 95% 置信区间 [86.7%, 97.1%]）；五个维度中仅原创性略升（+0.31），逻辑性、具体性、可操作性与整体质量分别下降 1.54、2.08、2.32 与 1.72 分。进一步分析表明，这一差距与输出长度高度相关（Spearman $\rho = 0.585$）：词对条件的正文被压缩到对照的 73%（`deepseek-flash`）与 46%（`deepseek-v4-pro`），而输出 token 数反而增至 2.02 倍与 1.60 倍；在长度比不低于 0.9 的子集（$n = 28$）上，胜率降至 67.9%；将长度差纳入回归后，等长处的条件效应由 −1.72 收窄至 −0.82（95% CI $[-1.38, -0.26]$）。机制上，词对块中的词元只有 16.9% 与 15.1% 原样出现在正文中。本文认为，该提示的主要后果是输出预算的重新分配与正文压缩，而非“从词中获得灵感”；据此提出等 token 预算、长度匹配与中性前缀对照三项设计修正。

关键词： 提示工程；大语言模型；盲评；长度偏差；中介分析；可复现性

Abstract. We independently recompute and re-analyze 240 blind pairwise comparisons from a public experiment that asks a model to first emit 200 word pairs and then answer an open-ended task. Direct answers win 224/240 comparisons (93.3%; task-clustered bootstrap 95% CI [86.7%, 97.1%]). Only originality improves (+0.31); logic, concreteness, actionability and overall quality drop by 1.54, 2.08, 2.32 and 1.72 points. The gap tracks answer length ($\rho = 0.585$): answer bodies after removing the pair block are 73% and 46% as long as baselines while consuming 2.02× and 1.60× as many output tokens; restricting to length ratio ≥ 0.9 reduces the baseline win rate to 67.9%, and a length-adjusted model puts the equal-length effect at −0.82 (95% CI $[-1.38, -0.26]$). Only 16.9% and 15.1% of paired tokens reappear in the answer. We argue the prompt mainly reallocates output budget rather than injecting inspiration, and propose equal-budget, length-matched and neutral-prefix controls.

Keywords: prompt engineering; large language models; pairwise judging; length bias; mediation analysis; reproducibility

1 引言

在中文大模型社区里流传着一种被称作“词对提示”的写法：在正式问题之前，要求模型先输出 200 组两词短语（例如“晨光 · 缓存”“指纹 · 钥匙”“日志 · 折线”），再“从这些词中获得灵感”作答。支持者的直觉是，随机的远距联想能把回答推离陈词滥调，产生更具原创性的方案。这个直觉并非空穴来风：心理学中的语义启动（semantic priming）表明，先前的词汇加工会改变后续概念的通达性 [?]；而在语言模型上，“先写出推理过程再给答案”也确实能在多步推理任务上带来稳定增益 [?, ?, ?]。但两者之间有一个关键差别：思维链的前置文本与答案共享同一套推理结构，其每一个中间步骤都被后续步骤使用；词对与答案之间却只有极弱的语义关联，前置生成主要是消耗同一份输出预算。

这类“前置生成”提示究竟带来什么，目前缺少可复核的证据。已有的提示敏感性研究反复表明，提示的表面形式——分隔符、格式、示例顺序、甚至与语义无关的模板——都可能显著改变模型表现 [?, ?, ?]，因此仅凭少量成功案例很难判断一个提示技巧的真实效应。与此同时，用大语言模型充当评委（LLM-as-a-judge）虽然与人类偏好高度相关 [?]，却已知存在位置偏差 [?]、冗长偏差 [?, ?] 与自我偏好 [?]。当评测对象是“更短还是更长”这类系统性差异时，评委的打分很容易把篇幅差异误读为质量差异。

本文不提出新的提示方法，而是对一个公开实验[1]做独立复算与再分析。该实验的原始结论是“词对提示显著降低了回答质量”。我们复算后确认了胜负计数与五维均分，但认为这一表述把一个“更短、更少细节”的差异包装成了“质量差异”，因而既高估了效应的普遍性，也错过了更有价值的机制问题。本文的贡献是：

(1) **独立复算**。从原始 JSONL 重新计算全部胜负、五维评分、评委一致性与位置效应，与仓库自报数字逐项对齐，并给出任务聚类的置信区间，纠正了把 240 对当作 240 个独立样本导致的显著性高估（朴素二项检验 $p \approx 4 \times 10^{-48}$，按任务聚类后 95% CI 为 $[86.7\%, 97.1\%]$）。

(2) **长度中介的定量证据**。通过分层、子集与含任务固定效应的回归，估计出长度差可解释约一半的评分差距；在长度相等处，条件效应由 -1.72 收窄至 -0.82。

(3) **机制证据**。给出“预算重分配”的直接测量：词对条件多花 60%–102% 的 token，却把正文压缩到 46%–73%；同时词对词元在正文中的原样复现率仅 15%–17%，说明“灵感”在字面上几乎没有兑现。

(4) **设计修正**。据此提出等 token 预算、长度匹配与中性前缀对照三项可操作的实验设计，并给出一份针对此类“前置生成”提示的效度清单。

2 相关工作

2.1 提示、推理与测试时计算

让模型“先写点什么再回答”是提示工程中最常见的结构。思维链提示通过少量示例引导模型输出中间推理步骤，在算术与常识推理上带来大幅提升 [?]；零样本条件下，“让我们一步一步思考”也能触发类似行为 [?]；自洽性方法进一步采样多条推理路径并投票 [?]。这些工作共享一个前提：前置文本承载了可复用的中间结果。与之相对，测试时计算的扩展研究表明，增加采样或

[1]数据与代码：`https://gitee.com/qwe12345678/jkdsfn`（提交 `88e0b9a`，原 `v2-deepseek` 分支）。

延长思考并不单调有益，其收益取决于任务难度与验证器的质量 [?]；对推理步长的分析也发现，步骤数与准确率之间并非简单的正相关 [?]。这提示我们：前置生成的价值不能由“写了更多”本身保证，而取决于写出来的内容是否被后续过程真正利用。

2.2 提示表面的敏感性

另一条线索关注提示中与任务语义无关的表面特征。文献 [?] 发现，用无意义的模板替换自然语言指令后，基于提示的模型表现下降有限，说明模型对指令“含义”的依赖弱于通常假设；文献 [?] 系统量化了分隔符、大小写、空格等格式扰动对性能的影响，发现其量级可与方法改进相当；文献 [?] 则指出，单提示评测的结论往往无法在提示集合上复现，呼吁多提示评测。这些结果共同说明：一个提示技巧的效应必须在多任务、多模型、并有恰当对照的条件下测量，否则很容易把格式或预算的副作用记在“技巧”头上。

2.3 LLM 评委的偏差

以模型作为评委已成为开放生成任务的主要评测手段。MT-Bench 与 Chatbot Arena 的实验显示，强模型评委与人类偏好的一致率可达 80% 以上 [?]，但其偏差同样明确：交换 A/B 位置会改变结论 [?]；评委倾向偏好更长、更繁冗的回答 [?]，这一偏差强到需要专门的长度控制方法才能在竞技场式评测中得到可比胜率 [?]；评委还会识别并偏袒自己生成的文本 [?]。本文的实验恰好同时具备这三个风险源：条件之间系统性存在长度差、生成与评审来自同一模型家族、且每个评委只评一次。

2.4 语义启动的隐喻及其边界

“词对”这一设计借用了心理学中语义启动的概念：先呈现一个词，会加快对语义相关词的加工 [?]。但把这一现象迁移到自回归语言模型时需要谨慎。启动效应作用于**外部刺激的加工速度**，而本文的条件作用于**同一段生成内部的上下文**：模型在写出 200 组词之后，这些词已经成为它自己的上文，既可能提供联想线索，也可能挤占本应用于答案的位置。前者是“灵感”，后者是“开销”，两者的净效应只能由实验区分——这正是本文要回答的问题。

2.5 随机刺激与发散—收敛提示

与“词对提示”最接近的先行工作分布在两条线上。第一条线是人类创造力方法。随机输入（random entry）是水平思考的核心工具之一：刻意引入一个与问题无关的随机词、图像或物件，借远距联想把思考推离惯常的方向 [?]；其心理学基础可追溯到远距联想理论——创造过程即把语义距离较远的反应联结成新颖而有用的组合 [?]。“词对提示”的直觉与这套方法几乎同构：200 组两词短语相当于一次大规模的随机输入，只是执行者从人换成了模型，且联想过程被写进了答案所在的同一段输出。

第二条线是 LLM 提示研究。文献 [?] 把随机词头脑风暴（random word brainstorming）引入 ChatGPT 提示：把**外部**选定的随机词注入提示以激发非常规方案，问卷评估显示人类被试在 20 个问题中的 65% 上更偏好该方法的产出。CREATIVEDC [?] 则提出“先发散、后收敛”的两阶

段提示：模型先在同一次输出内头脑风暴一组非常规场景，再从中选取素材构造编程练习，产出的高效用且互异任务数约为基线的 1.6 倍。后者与词对提示在结构上最为相近——前置的发散文本与最终答案共享同一上下文与同一份输出预算——但其因变量是任务多样性而非盲评质量，也未对两条件做预算或长度上的控制。

把这两条线放在一起，可以澄清本文的定位。其一，“用随机联想激发模型”并非新提议：它在创造力工程中已有半个多世纪的历史，在 LLM 上也至少自 2023 年起就有正式研究；本文的增量不在提出该技巧，而在于对它的社区流传变体（模型**自生成**词对、前置文本与答案**共享预算**）给出可复核的负结果与机制解释。其二，先行工作的正面结论（新颖性偏好、多样性提升）与原实验的负面结论（质量下降）表面上冲突，实则度量的是不同的因变量，且都缺少等预算、长度匹配与中性前缀对照——这正是第 **??** 节三项设计修正试图补齐的缺口。

3 实验与数据

3.1 设计与材料

原实验采用 $6 \times 2 \times 10$ 的完全交叉设计：6 个开放式中文任务，2 个条件，每个单元重复 10 次。任务覆盖“设计一门函数式编程语言”“低成本提升现有 LLM 性能”“面向独立开发者的 CLI 工具创意”“提出一个新理论”“提出一个类九型人格/荣格八维的新模型”“提出一种新的机器学习架构”，均属于没有唯一答案的开放式创意任务。两个条件只在提示前缀上不同：

- `baseline`：直接给出任务提示；
- `word_pairs`：在任务提示前加一句“在回答前面输出 200 组词，每组有两个词，从这些词获得灵感”。

表 1 汇总了实验配置。需要强调的是，两条件共享同一模型、同一温度（生成 0.6，清洗与评审 0.3）、同一输出上限，唯一差别就是那句前缀，因此这是一个干净的单因素操纵。

表 1　实验配置

项目	设置
任务	6 个开放式中文任务（见表 2）
条件	`baseline`（直接回答）vs. `word_pairs`（先写 200 组词对再回答）
重复	每“任务 × 条件”10 次
生成模型	`deepseek-flash`、`deepseek-v4-pro`
评委	同上两个模型，交叉评审（2×2 共 4 格）
规模	240 条生成 / 120 条清洗 / 240 对盲评
评分	logic、concreteness、actionability、originality、overall，1–10 分
位置平衡	按（生成模型、评委、任务、run）的确定性哈希决定 A/B 顺序，每对评一次
清洗	由生成同款模型删除开头词对块与“第 N 组”类引用，正则复查残留

表 2 六个任务及其提示语（节选）

编号	简称	任务提示（原文节选）
1	函数式语言	设计一个全新的函数式编程语言
2	提升 LLM	怎么低成本不需要额外训练大幅提升现有 LLM 的性能
3	CLI 工具	给出适合独立开发者开发 CLI 工具的一个 Idea
4	新理论	提出一个新的理论
5	人格模型	提出一个新的类似于九型和荣格八维的模型
6	ML 架构	提出一个新的机器学习架构

3.2 清洗与盲评

`word_pairs` 的原始输出以词对块开头，若直接与 `baseline` 比较，评委看到的将是“词对 + 答案”对“答案”，差异会被词对块本身的篇幅主导。为此原实验引入清洗步骤：由同一模型删除词对块及正文中对词对的引用（如“从上面词对中”“第 12 组”），得到 `cleaned` 文本，再用正则检查是否仍有编号或指代残留。复算显示 120 条清洗结果全部无残留，清洗后文本与清洗前正文（原始输出去掉词对块后的部分）的长度比中位数为 0.99，均值 0.979，最小 0.635——即清洗基本是“删掉词块 + 轻度改写”，个别样本存在较大幅度删改。

盲评阶段，评委看到两段匿名文本 A 与 B，被要求按五个维度各打 1–10 分，并给出胜负与理由。五个维度的操作化定义为：逻辑性（论证是否自洽、结构是否清楚）、具体性（是否有具体方案、参数与例子）、可操作性（读者能否照着实施）、原创性（是否给出新颖的视角或组合）、整体质量（综合判断）。评委以 JSON 输出胜负（A/B/tie）与一段自由文本理由，温度为 0.3，每对只评一次、不做多次采样平均。需要说明的是，五个维度并不正交，整体质量与其余四维高度相关；因此本文以整体质量为主结果，其余维度用于解释差异来源，而不单独作为“独立假设”检验。A/B 顺序由确定性哈希决定，每条记录保存了 `swap`、`A_source`、`B_source`，因此事后可以把分数还原到条件，也可以分解位置效应。这一点在原仓库中做得比多数同类实验规范。

3.3 数据完整性与分析口径

我们从仓库的 8 个 JSONL 文件（2 个生成模型 × 4 类记录）重算，未使用仓库自带的汇总文件。所有阶段均为追加式写入，重复记录按 `(task_id, condition, run)` 或 `(task_id, run)` 取最新有效记录；生成 240 条（每模型 120 条）、清洗 120 条、盲评 240 对，无缺失、无重复。

全文统一记号：Δ 表示“词对条件 − 直接回答”，故 $\Delta < 0$ 表示词对条件更差；除表 **??** 的生成侧统计外，长度一律指评委实际看到的字符数（`baseline_content` 与 `cleaned_content` 的长度），而非模型原始输出。统计上，我们把 6 个任务视为 6 个簇：由于同一任务内的 40 对共享同一提示，它们并不独立，因此主结果报告按任务重抽样的聚类 bootstrap（$B = 10\,000$）置信区间，并辅以任务层面的符号检验；回归模型均含任务固定效应与任务聚类稳健标准误。所有分析脚本与中间结果随文提供，可一键复现。