# 先写 200 组词对能提升回答质量吗？

## ——对一项 240 对盲评实验的独立复算与再分析

作者姓名[1]

[1] 单位名称，城市邮编

email@example.com

**摘要**

在问题前加一句“先输出 200 组两词短语，再从中获得灵感”，是中文大模型社区流行的一种“灵感注入”式提示。本文对一个公开实验的 240 对盲评数据做独立复算与再分析。该实验覆盖 6 个开放式任务、2 个生成模型、2 个评委，每个“任务 × 条件”单元重复 10 次。复算显示：直接回答在 224/240 对中获胜（93.3%，任务聚类 bootstrap 95% 置信区间 [86.7%, 97.1%]）；五个维度中仅原创性略升（+0.31），逻辑性、具体性、可操作性与整体质量分别下降 1.54、2.08、2.32 与 1.72 分。进一步分析表明，这一差距与输出长度高度相关（Spearman $\rho = 0.585$）：词对条件的正文被压缩到对照的 73%（`deepseek-flash`）与 46%（`deepseek-v4-pro`），而输出 token 数反而增至 2.02 倍与 1.60 倍；在长度比不低于 0.9 的子集（$n = 28$）上，胜率降至 67.9%；将长度差纳入回归后，等长处的条件效应由 −1.72 收窄至 −0.82（95% CI [−1.38, −0.26]）。机制上，词对块中的词元只有 16.9% 与 15.1% 原样出现在正文中。本文认为，该提示的主要后果是输出预算的重新分配与正文压缩，而非“从词中获得灵感”；据此提出等 token 预算、长度匹配与中性前缀对照三项设计修正。

**关键词：** 提示工程；大语言模型；盲评；长度偏差；中介分析；可复现性

**Abstract.** We independently recompute and re-analyze 240 blind pairwise comparisons from a public experiment that asks a model to first emit 200 word pairs and then answer an open-ended task. Direct answers win 224/240 comparisons (93.3%; task-clustered bootstrap 95% CI [86.7%, 97.1%]). Only originality improves (+0.31); logic, concreteness, actionability and overall quality drop by 1.54, 2.08, 2.32 and 1.72 points. The gap tracks answer length ($\rho = 0.585$): cleaned answers are 73% and 46% as long as baselines while consuming 2.02× and 1.60× more output tokens; restricting to length ratio $\geq 0.9$ reduces the baseline win rate to 67.9%, and a length-adjusted model puts the equal-length effect at −0.82 (95% CI [−1.38, −0.26]). Only 16.9% and 15.1% of paired tokens reappear in the answer. We argue the prompt mainly reallocates output budget rather than injecting inspiration, and propose equal-budget, length-matched and neutral-prefix controls.

**Keywords:** prompt engineering; large language models; pairwise judging; length bias; mediation analysis; reproducibility

# 1 引言

在中文大模型社区里流传着一种被称作“词对提示”的写法：在正式问题之前，要求模型先输出 200 组两词短语（例如“晨光 · 缓存”“指纹 · 钥匙”“日志 · 折线”），再“从这些词中获得灵感”作答。支持者的直觉是，随机的远距联想能把回答推离陈词滥调，产生更具原创性的方案。这个直觉并非空穴来风：心理学中的语义启动（semantic priming）表明，先前的词汇加工会改变后续概念的通达性 [1]；而在语言模型上，“先写出推理过程再给答案”也确实能在多步推理任务上带来稳定增益 [2, 3, 4]。但两者之间有一个关键差别：思维链的前置文本与答案共享同一套推理结构，其每一个中间步骤都被后续步骤使用；词对与答案之间却只有极弱的语义关联，前置生成主要是消耗同一份输出预算。

这类“前置生成”提示究竟带来什么，目前缺少可复核的证据。已有的提示敏感性研究反复表明，提示的表面形式——分隔符、格式、示例顺序、甚至与语义无关的模板——都可能显著改变模型表现 [5, 6, 7]，因此仅凭少量成功案例很难判断一个提示技巧的真实效应。与此同时，用大语言模型充当评委（LLM-as-a-judge）虽然与人类偏好高度相关 [8]，却已知存在位置偏差 [9]、冗长偏差 [10, 11] 与自我偏好 [12]。当评测对象是“更短还是更长”这类系统性差异时，评委的打分很容易把篇幅差异误读为质量差异。

本文不提出新的提示方法，而是对一个公开实验[1]做独立复算与再分析。该实验的原始结论是“词对提示显著降低了回答质量”。我们复算后确认了胜负计数与五维均分，但认为这一表述把一个“更短、更少细节”的差异包装成了“质量差异”，因而既高估了效应的普遍性，也错过了更有价值的机制问题。本文的贡献是：

(1) **独立复算**。从原始 JSONL 重新计算全部胜负、五维评分、评委一致性与位置效应，与仓库自报数字逐项对齐，并给出任务聚类的置信区间，纠正了把 240 对当作 240 个独立样本导致的显著性高估（朴素二项检验 $p \approx 4 \times 10^{-48}$，按任务聚类后 95% CI 为 $[86.7\%, 97.1\%]$）。

(2) **长度中介的定量证据**。通过分层、子集与含任务固定效应的回归，估计出长度差可解释约一半的评分差距；在长度相等处，条件效应由 $-1.72$ 收窄至 $-0.82$。

(3) **机制证据**。给出“预算重分配”的直接测量：词对条件多花约一倍 token，却把正文压缩到 46%–73%；同时词对词元在正文中的原样复现率仅 15%–17%，说明“灵感”在字面上几乎没有兑现。

(4) **设计修正**。据此提出等 token 预算、长度匹配与中性前缀对照三项可操作的实验设计，并给出一份针对此类“前置生成”提示的效度清单。

# 2 相关工作

## 2.1 提示、推理与测试时计算

让模型“先写点什么再回答”是提示工程中最常见的结构。思维链提示通过少量示例引导模型输出中间推理步骤，在算术与常识推理上带来大幅提升 [2]；零样本条件下，“让我们一步一步思考”也能触发类似行为 [3]；自洽性方法进一步采样多条推理路径并投票 [4]。这些工作共享一个前提：前置文本承载了可复用的中间结果。与之相对，测试时计算的扩展研究表明，增加采样

[1] 数据与代码：`https://gitee.com/qwe12345678/jkdsfn`（分支 `v2-deepseek`，提交 `88e0b9a`）。

或延长思考并不单调有益，其收益取决于任务难度与验证器的质量 [13]；对推理步长的分析也发现，步骤数与准确率之间并非简单的正相关 [14]。这提示我们：前置生成的价值不能由“写了更多”本身保证，而取决于写出来的内容是否被后续过程真正利用。

### 2.2 提示表面的敏感性

另一条线索关注提示中与任务语义无关的表面特征。文献 [6] 发现，用无意义的模板替换自然语言指令后，基于提示的模型表现下降有限，说明模型对指令“含义”的依赖弱于通常假设；文献 [5] 系统量化了分隔符、大小写、空格等格式扰动对性能的影响，发现其量级可与方法改进相当；文献 [7] 则指出，单提示评测的结论往往无法在提示集合上复现，呼吁多提示评测。这些结果共同说明：一个提示技巧的效应必须在多任务、多模型、并有恰当对照的条件下测量，否则很容易把格式或预算的副作用记在“技巧”头上。

### 2.3 LLM 评委的偏差

以模型作为评委已成为开放生成任务的主要评测手段。MT-Bench 与 Chatbot Arena 的实验显示，强模型评委与人类偏好的一致率可达 80% 以上 [8]，但其偏差同样明确：交换 A/B 位置会改变结论 [9]；评委倾向偏好更长、更繁冗的回答 [10]，这一偏差强到需要专门的长度控制方法才能在竞技场式评测中得到可比胜率 [11]；评委还会识别并偏袒自己生成的文本 [12]。本文的实验恰好同时具备这三个风险源：条件之间系统性存在长度差、生成与评审来自同一模型家族、且每个评委只评一次。

### 2.4 语义启动的隐喻及其边界

“词对”这一设计借用了心理学中语义启动的概念：先呈现一个词，会加快对语义相关词的加工 [1]。但把这一现象迁移到自回归语言模型时需要谨慎。启动效应作用于**外部刺激的加工速度**，而本文的条件作用于**同一段生成内部的上下文**：模型在写出 200 组词之后，这些词已经成为它自己的上文，既可能提供联想线索，也可能挤占本应用于答案的位置。前者是“灵感”，后者是“开销”，两者的净效应只能由实验区分——这正是本文要回答的问题。

## 3 实验与数据

### 3.1 设计与材料

原实验采用 $6 \times 2 \times 10$ 的完全交叉设计：6 个开放式中文任务，2 个条件，每个单元重复 10 次。任务覆盖“设计一门函数式编程语言”“低成本提升现有 LLM 性能”“面向独立开发者的 CLI 工具创意”“提出一个新理论”“提出一个类九型人格/荣格八维的新模型”“提出一种新的机器学习架构”，均属于没有唯一答案的开放式创意任务。两个条件只在提示前缀上不同：

- `baseline`：直接给出任务提示；
- `word_pairs`：在任务提示前加一句“在回答前面输出 200 组词，每组有两个词，从这些词获得灵感”。

表 1 汇总了实验配置。需要强调的是，两条件共享同一模型、同一温度（生成 0.6，清洗与评审 0.3）、同一输出上限，唯一差别就是那句前缀，因此这是一个干净的单因素操纵。

表 1 实验配置

| 项目 | 设置 |
|---|---|
| 任务 | 6 个开放式中文任务（见表 2） |
| 条件 | `baseline`（直接回答）vs. `word_pairs`（先写 200 组词对再回答） |
| 重复 | 每“任务 × 条件”10 次 |
| 生成模型 | `deepseek-flash`、`deepseek-v4-pro` |
| 评委 | 同上两个模型，交叉评审（$2 \times 2$ 共 4 格） |
| 规模 | 240 条生成 / 120 条清洗 / 240 对盲评 |
| 评分 | logic、concreteness、actionability、originality、overall，1–10 分 |
| 位置平衡 | 按 `pair_id` 的确定性哈希决定 A/B 顺序，每对评一次 |
| 清洗 | 由生成同款模型删除开头词对块与“第 $N$ 组”类引用，正则复查残留 |

表 2 六个任务及其提示语（节选）

| 编号 | 简称 | 任务提示（原文节选） |
|---|---|---|
| 1 | 函数式语言 | 设计一个全新的函数式编程语言 |
| 2 | 提升 LLM | 怎么低成本、不需要额外训练地大幅提升现有 LLM 的性能 |
| 3 | CLI 工具 | 给出适合独立开发者开发 CLI 工具的一个 Idea |
| 4 | 新理论 | 提出一个新的理论 |
| 5 | 人格模型 | 提出一个新的类似于九型和荣格八维的模型 |
| 6 | ML 架构 | 提出一个新的机器学习架构 |

### 3.2 清洗与盲评

`word_pairs` 的原始输出以词对块开头，若直接与 `baseline` 比较，评委看到的将是“词对 + 答案”对“答案”，差异会被词对块本身的篇幅主导。为此原实验引入清洗步骤：由同一模型删除词对块及正文中对词对的引用（如“从上面词对中”“第 12 组”），得到 `cleaned` 文本，再用正则检查是否仍有编号或指代残留。复算显示 120 条清洗结果全部无残留，清洗正文与原始正文的长度比中位数为 0.99，均值 0.979，最小 0.635——即清洗基本是“删掉词块 + 轻度改写”，个别样本存在较大幅度删改。

盲评阶段，评委看到两段匿名文本 A 与 B，被要求按五个维度各打 1–10 分，并给出胜负与理由。五个维度的操作化定义为：逻辑性（论证是否自洽、结构是否清楚）、具体性（是否有具体方案、参数与例子）、可操作性（读者能否照着实施）、原创性（是否给出新颖的视角或组合）、整体质量（综合判断）。评委以 JSON 输出胜负（A/B/tie）与一段自由文本理由，温度为 0.3，每对只评一次、不做多次采样平均。需要说明的是，五个维度并不正交，整体质量与其余四维高度相关；因此本文以整体质量为主结果，其余维度用于解释差异来源，而不单独作为“独立假设”检

验。A/B 顺序由确定性哈希决定，每条记录保存了 `swap`、`A_source`、`B_source`，因此事后可以把分数还原到条件，也可以分解位置效应。这一点在原仓库中做得比多数同类实验规范。

### 3.3 数据完整性与分析口径

我们从仓库的 8 个 JSONL 文件（2 个生成模型 × 4 类记录）重算，未使用仓库自带的汇总文件。所有阶段均为追加式写入，重复记录按 `(task_id, condition, run)` 或 `(task_id, run)` 取最新有效记录；生成 120 条、清洗 120 条、盲评 240 对，无缺失、无重复。

全文统一记号：$\Delta$ 表示“词对条件 − 直接回答”，故 $\Delta < 0$ 表示词对条件更差；长度一律指评委实际看到的字符数（`baseline_content` 与 `cleaned_content` 的长度），而非模型原始输出。统计上，我们把 6 个任务视为 6 个簇：由于同一任务内的 40 对共享同一提示，它们并不独立，因此主结果报告按任务重抽样的聚类 bootstrap（$B = 10\,000$）置信区间，并辅以任务层面的符号检验；回归模型均含任务固定效应与任务聚类稳健标准误。所有分析脚本与中间结果随文提供，可一键复现。

## 4 结果

### 4.1 主效应：直接回答的压倒性优势

240 对盲评中，直接回答胜 224 对，词对条件胜 15 对，平 1 对，胜率 93.3%。四个“生成模型 × 评委”格子的方向完全一致（表 3），从 52/60 到 59/60 不等。格子之间的差异本身也有信息：以 `deepseek-v4-pro` 为生成模型的两格几乎完全相同（均为 59:1），而以 `deepseek-flash` 为生成模型的两格分别为 54:5 与 52:8——同一批文本换一个评委，词对条件的胜场就从 5 变成 8。这说明受损程度首先取决于生成模型如何分配预算，评委的宽严只带来二阶波动。按任务聚类后，胜率的 95% 置信区间为 $[86.7\%, 97.1\%]$，$\Delta_{\text{overall}}$ 的均值为 $-1.72$，95% CI $[-2.04, -1.38]$。六个任务无一例外地偏向直接回答，符号检验的双侧精确 $p = 0.031$。作为对照，若错误地把 240 对视为独立样本，二项检验会给出 $p \approx 4 \times 10^{-48}$——这一数量级的差异正是聚类校正的意义所在。

表 3　主结果：四格胜负与分差（$N = 240$）

| 格子（生成 / 评委） | $n$ | 胜负 | | | $\Delta_{\text{overall}}$ | $\Delta_{\text{orig.}}$ |
|---|---|---|---|---|---|---|
| | | 直接 | 词对 | 平 | | |
| `deepseek-flash` / `deepseek-flash` | 60 | 54 | 5 | 1 | −1.27 | +0.52 |
| `deepseek-flash` / `deepseek-v4-pro` | 60 | 52 | 8 | 0 | −1.05 | +0.65 |
| `deepseek-v4-pro` / `deepseek-flash` | 60 | 59 | 1 | 0 | −2.38 | −0.22 |
| `deepseek-v4-pro` / `deepseek-v4-pro` | 60 | 59 | 1 | 0 | −2.18 | +0.30 |
| 合计 | 240 | 224 | 15 | 1 | −1.72 | +0.31 |

注：$\Delta$ 为“词对条件 − 直接回答”的均分差。胜率 93.3%，任务聚类 bootstrap 95% CI $[86.7\%, 97.1\%]$。

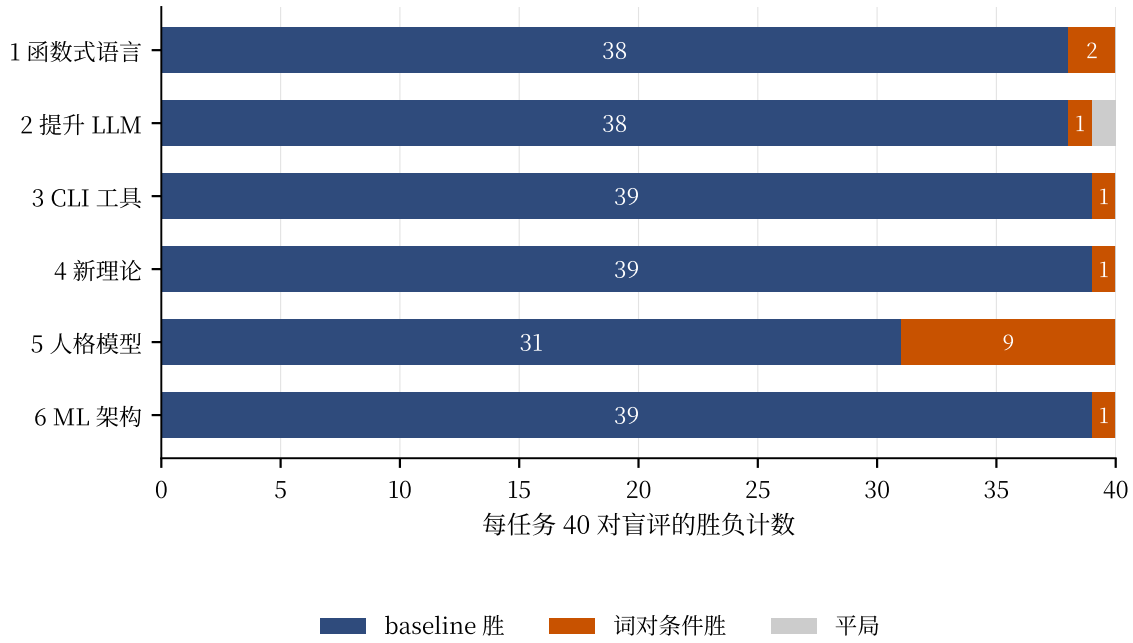



图 1 分任务胜负分布（每任务 40 对）。任务 5“人格模型”是唯一出现较多词对胜场的任务。

### 4.2 维度分解：只赢在原创性

表 4 与图 2 把五维评分还原到条件后合并 240 对。词对条件在四个维度上全面落后：可操作性 −2.32、具体性 −2.08、整体质量 −1.72、逻辑性 −1.54，唯一为正的是原创性 +0.31（$d_z = 0.25$）。分生成模型看，原创性收益主要来自 `deepseek-flash`（+0.58），`deepseek-v4-pro` 上几乎为零（+0.04）——这与“词对能稳定提升创造力”的说法不符，说明该收益依赖生成模型。

从效应量看，四个负向维度的 $d_z$ 在 −1.25 至 −1.48 之间，按常规标准属于大效应。但这一数值部分来自评分尺度的天花板：直接回答的均分已接近 9 分，质量下降被压缩在高分区间内，因而 $d_z$ 同时混合了“真实下降”与“尺度非线性”两种成分，不宜与心理学实验中的效应量直接类比。原创性的 $d_z = 0.25$ 处于小效应区间；在只有 6 个簇、且评委只评一次的条件下，其不确定性很大，本文只把它当作方向性证据，而不据此主张“词对能提升创造力”。

表 4 五维评分：条件均值与配对效应量（$N = 240$）

| 维度 | 直接回答 | 词对条件 | Δ | Cohen's $d_z$ |
|---|---|---|---|---|
| 逻辑性 logic | 8.98 | 7.44 | −1.54 | −1.25 |
| 具体性 concreteness | 8.90 | 6.83 | −2.08 | −1.36 |
| 可操作性 actionability | 8.67 | 6.35 | −2.32 | −1.48 |
| 原创性 originality | 7.54 | 7.85 | +0.31 | +0.25 |
| 整体质量 overall | 8.83 | 7.11 | −1.72 | −1.36 |

### 4.3 任务异质性：发散任务更受益

图 1 显示，五个任务的直接回答胜率都在 95% 以上，唯独任务 5“人格模型”为 77.5%（31:9）。这一差异有直观解释：提出一个类九型人格的模型需要在多个心理维度间做类比与组合，词对提

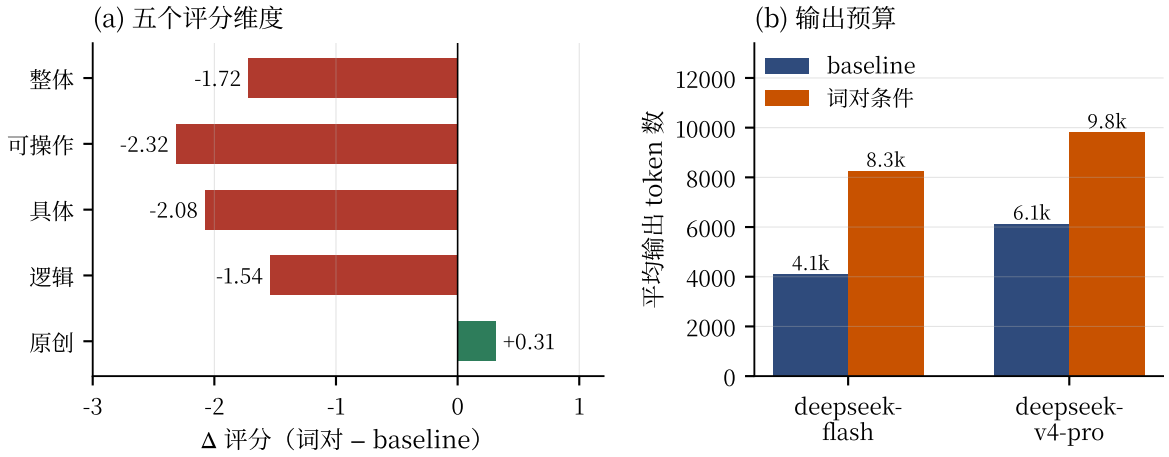



图 2 (a) 五个维度的均分差；(b) 两条件的平均输出 token 数。词对条件多花约一倍预算，却在四个质量维度上同时下降。

供的远距联想恰好能充当素材；而“设计一门编程语言”“提出一个新理论”这类任务有较强的内在结构要求，压缩后的正文更容易丢掉定义、机制与可检验预测。也就是说，词对条件并非在所有任务上同等有害，其收益与代价取决于任务对“发散联想”和“结构细节”的相对需求。任务 5 也是任务内长度—分数相关最高的一格（$\rho = 0.89$，$\rho^2 \approx 0.79$）：该任务的评分高度由篇幅决定，因此它虽然最“受益”，胜率也只是从其余五个任务的平均 96.5% 降到 77.5%，并未真正翻转。

### 4.4 关键发现：长度是主要通道

表 5 按“词对正文长度 / 直接回答长度”分层。胜率随长度比单调上升：长度比低于 0.5 的 100 对中直接回答全胜；长度比高于 1.2 的 8 对中词对条件胜 6 对。把长度比不低于 0.9 的 28 对单独取出，胜率从 93.3% 降至 67.9%，平均分差从 $-1.72$ 收窄到 $-0.50$；若要求词对正文至少与直接回答等长（$n = 18$），胜负变为 9:9，平均分差 $-0.22$。在 $\pm 15\%$ 的长度带内（$n = 26$），胜率仍有 76.9%，但分差已降至 $-0.65$。240 对的 Spearman 相关为 $\rho = 0.585$（$p < 10^{-23}$），逐格相关在 0.30–0.50 之间，方向一致。把样本按任务切开分别计算，$\rho$ 落在 0.37–0.89 之间（中位 0.56），六个任务全部为正且 $p < 0.02$——这说明长度效应不是某一两个任务造成的伪影，而是贯穿整个任务集的稳定结构。

图 3 把 240 个点与分箱均值画在一起。可以看到两点：其一，分箱均值几乎落在一条对数曲线上，说明长度与评分的关系是连续而非阈值式的；其二，即便在长度比接近 1 的位置，均值仍在零线以下，提示长度并非唯一通道。

为给出可解释的定量结论，我们拟合含任务固定效应的回归 $\Delta_{\text{overall}} = \alpha + \beta \ln(L_{\text{wp}}/L_{\text{base}}) + \gamma_{\text{task}} + \varepsilon$，标准误按任务聚类。结果为 $\beta = 1.65$（$SE = 0.30$，$t = 5.42$，$\text{df} = 5$，$p = 0.003$），$\alpha = -0.82$（95% CI $[-1.38, -0.26]$）。斜率可读作“长度比每提高一个自然对数单位（即乘以 $e$），分差改善 1.65 分”；截距则给出**长度相等时仍残留的条件差异**，其绝对值约为原始均值差 $-1.72$ 的 48%。也就是说，长度差大致解释了一半的评分差距，另一半来自长度之外的因素。

这里需要明确因果语言。长度不是普通混杂变量，而是**处理后变量**（post-treatment mediator）：条件影响长度，长度又影响评分。对中介变量分层或回归，得到的是“若长度被固定，效应会是多少”的反事实估计，而不是无偏的因果效应；若还存在同时影响长度与评分的未观测因素（例

表 5 按长度比分层的胜负与分差

| 长度比区间 | $n$ | 直接胜 | 词对胜 | 平 | $\Delta_{\text{overall}}$ |
|---|---|---|---|---|---|
| $< 0.5$ | 100 | 100 | 0 | 0 | −2.50 |
| 0.5–0.8 | 96 | 92 | 4 | 0 | −1.36 |
| 0.8–1.0 | 26 | 23 | 2 | 1 | −1.08 |
| 1.0–1.2 | 10 | 7 | 3 | 0 | −0.70 |
| $> 1.2$ | 8 | 2 | 6 | 0 | +0.38 |
| 子集：长度比 $\geq 0.9$ | 28 | 19 | 9 | 0 | −0.50 |
| 子集：长度比 $\geq 1.0$ | 18 | 9 | 9 | 0 | −0.22 |
| 子集：$\lvert$长度比 $- 1\rvert \leq 0.15$ | 26 | 20 | 5 | 1 | −0.65 |

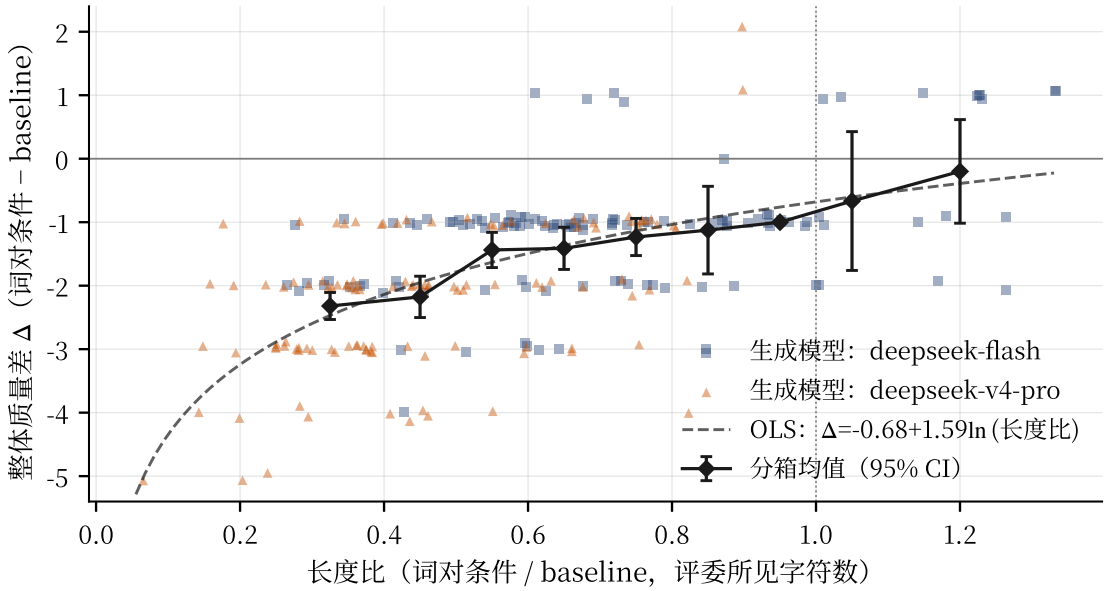



图 3 长度比与整体质量差的关系。散点为 240 对，黑线为分箱均值（95% CI），虚线为 $\Delta = a + b\ln(\text{长度比})$ 的最小二乘拟合。

如模型在长任务上的“耐心”），估计仍可能有偏。因此本文的结论是“长度是主要通道之一，约解释一半”，而不是“词对没有效果”。剩余的那一半，一部分可能来自清洗过程中被删掉的细节，一部分来自词对条件本身更差的组织结构——下一节的文本特征分析支持这一解读。

### 4.5 预算重分配：多花一倍 token，写得更短

表 6 给出生成侧的测量。词对条件的平均输出 token 是直接回答的 2.02 倍（`deepseek-flash`：4090→8252）与 1.60 倍（`deepseek-v4-pro`：6123→9796），但清洗后的正文只有对照的 73% 与 46%。把词对块单列出来看，其长度约 2 290–2 440 字符，相当于一篇直接回答的 68%–82%；换言之，模型把相当一部分输出预算花在了与答案无关的清单上。

值得强调的是，缩短并非被动截断。两个条件共享同一输出上限（数据中观测到的最大输出为 16 383/16 384 个 token）。120 条词对输出中只有 3 条真正触顶，且这 3 条都缺少收尾标点；另有 1

表 6 输出预算与正文长度（每条件 60 条）

| 指标 | deepseek-flash | | deepseek-v4-pro | |
|---|---|---|---|---|
| | 直接回答 | 词对条件 | 直接回答 | 词对条件 |
| 平均输出 token | 4 090 | 8 252 | 6 123 | 9 796 |
| 平均输出字符 | 2 774 | 4 318 | 3 576 | 4 090 |
| 其中正文平均字符 | 2 774 | 2 031 | 3 576 | 1 653 |
| 正文 / 直接回答 | 1.00 | 0.73 | 1.00 | 0.46 |
| 词对条数（均值） | – | 199.9 | – | 192.3 |
| 词元原样复现率 | – | 16.9% | – | 15.1% |
| 触及输出上限条数 | 0 | 1 | 0 | 2 |

条未触顶、同样没有收尾标点，其余 116 条都以正常标点结束。也就是说，模型在写完词对之后，**主动**把答案压缩了：它仍有预算，但选择了更短的答复。这与“预算不足”不同，更像一种自我节流——模型把“已经写了很多”当成了停止的理由。这一机制也解释了为什么 deepseek-v4-pro 受损更重：它的词对块更长、正文压缩更狠（0.46），对应的分差也更大（$-2.28$ 对 $-1.16$）。

### 4.6 机制检验：词对真的被“用上”了吗

如果词对的作用是“提供灵感”，那么词对中的词应当以某种形式进入正文。我们把词对块中的 2–4 字中文词元与英文词抽取出来，检查其是否原样出现在正文中（这是覆盖率的下界，忽略改写、同义与词形变化）。结果为：deepseek-flash 平均 16.9%（中位 14.0%，最高 50.9%），deepseek-v4-pro 平均 15.1%（中位 13.3%，最高 73.2%）。即便按最宽松的口径，也有八成以上的词没有被使用。

词对的排版也提示处理并未标准化：deepseek-flash 基本采用“每行一组”（如“1. 终端 · 灵感”），deepseek-v4-pro 则混用“每行十组、以分号分隔”“三位补零（001.）”“【1–10】分块”等至少四种格式。这不影响本文的结论，但它意味着任何按行计数的剂量校验都会严重低估词对数量；若后续研究要复核处理强度，必须在生成时就记录 pair_count，而不是事后用正则去猜。

与之对照，200 组词对基本都写满了（前者全部 $\geq 191$ 组，后者 59/60 达到 190 组以上），说明模型并未偷工减料，低复现率不是因为词没写出来，而是因为写出来的词大多与后续答案无关。

把这一结果与上一节合起来看，词对条件的因果链条更像是：**前置清单占用预算 → 正文被压缩 → 细节与结构减少 → 评分下降**，而不是“词对激发联想 → 答案更有创意”。原创性上的小幅提升说明前者并非完全没有副产物，但其量级（+0.31，且仅在一个生成模型上成立）远不足以抵消其他维度的损失。

### 4.7 评委行为：位置、宽严与天花板

用 $2 \times 2$ 分解可以把评委看到的差异拆成条件效应与位置效应：当 A 为直接回答时，$A - B$ 的均值为 $+2.12$；当 A 为词对条件时，$A - B$ 为 $-1.37$。由此得到条件效应 $+1.74$、位置效应 $+0.37$。位置偏差存在但不是主因；不过由于 A/B 顺序由哈希而非分层平衡决定，直接回答落在

A 位的对数为 113/240，位置与样本并不完全独立，这一点会放大噪声。

两位评委的一致性也值得注意。对 `deepseek-flash` 的 60 对，两位评委一致 52 对（86.7%），Cohen's $\kappa = 0.36$，属于弱一致；对 `deepseek-v4-pro` 的 60 对，一致性为 100%，$\kappa = 1.00$——但这个“完美一致”是边际分布极度失衡（59:1）造成的假象：当几乎所有人都判直接回答胜时，任何评委都会“同意”，$\kappa$ 被抬高并不代表评委可靠。两位评委的宽严也不同：`deepseek-flash` 作为评委时，五维均分为 8.09（评审 `deepseek-flash` 文本）与 8.22（评审 `deepseek-v4-pro` 文本）；`deepseek-v4-pro` 作为评委时为 7.46 与 7.63，系统性低约 0.6 分。这意味着绝对分数不可跨评委比较，只有同一评委内的相对比较才有意义。

评分还明显存在天花板效应（图 4）：480 个整体分中，9 分 216 个（45%）、8 分 128 个，10 分仅 2 个，均值 7.97、标准差 1.26。分布集中在高分段会压缩区分度，也会让“某一维度略高”这类小效应更难被可靠检出。评审理由的词频分析同样指向篇幅：“可操作”出现 184 次、“结构”168 次、“具体”158 次、“完整”148 次、“清晰”144 次、“细节”140 次——评委在解释自己的偏好时，反复使用的正是短答案最容易缺失的属性。

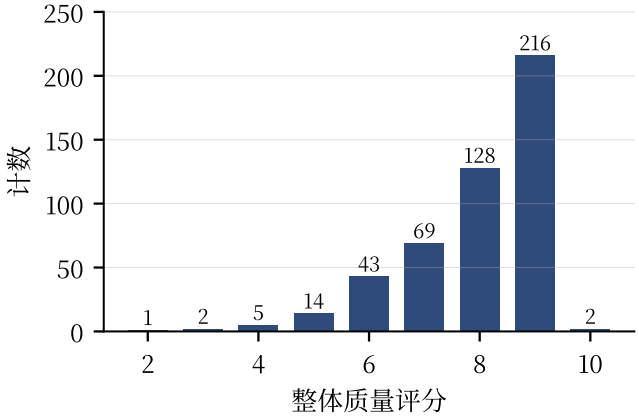



图 4　480 个整体质量评分的分布。45% 为 9 分，天花板效应明显。

### 4.8　文本特征：评分在追踪什么

为验证“评分随篇幅与结构走”的判断，我们抽取了若干与长度相关的客观特征，计算其条件间差值与 $\Delta_{\text{overall}}$ 的 Spearman 相关：字符数 0.541、段落数 0.480、标题数 0.441、数字个数 0.357、加粗片段 0.236、列表项 0.201。以标准化特征差与任务固定效应做多元回归，字符数（$\beta = 0.84$，$SE = 0.28$）与标题数（$\beta = 0.17$，$SE = 0.05$）显著为正，代码块数为负（$\beta = -0.25$，$SE = 0.08$），$R^2 = 0.47$。也就是说，近一半的评分方差可以由“答案变短了多少、结构少了多少”解释。这与 LLM 评委的冗长偏差文献一致 [10, 11]，但在本文中它不只是评测噪声：词对条件确实系统性地删掉了细节与结构，评委的偏好与文本的实际变化方向相同，两者叠加，才产生了 93% 的胜率。

### 4.9　跨代复现：v1 的方向一致、量级更小

同一仓库还包含一代更早的实验（v1）：使用 `moonshotai/kimi-k3` 作为生成与评审模型，每格 10 次、共 60 对。复算结果（表 7）为 49:10:1（直接回答胜率 81.7%），五维方向与 v2 完全一致（整体 −1.03、可操作性 −1.65、原创性 +1.10）。更有意思的是长度：v1 的词对正文为对照的

84.1%, 远没有 v2 那么极端; 相应的胜率也更低 (81.7% 对 93.3%), 长度—分数相关为 $\rho = 0.359$, 在长度比不低于 0.9 的 17 对上胜率降至 64.7%。

表 7 两代实验的对照：长度压缩越强，胜率差距越大

| 项目 | v1（Kaggle） | v2（本地，本文主分析） |
|---|---|---|
| 生成 / 评审模型 | kimi-k3 / 同模型 | `deepseek-flash` 与 `deepseek-v4-pro` 交叉评审 |
| 有效对数 | 60 | 240 |
| 胜负（直接: 词对: 平） | 49:10:1 | 224:15:1 |
| 直接回答胜率 | 81.7% | 93.3% |
| $\Delta_{\text{overall}}$ | $-1.03$ | $-1.72$ |
| $\Delta_{\text{originality}}$ | $+1.10$ | $+0.31$ |
| 正文长度比（均值） | 0.841 | 0.585 |
| Spearman $\rho$（长度比, $\Delta$） | 0.359 | 0.585 |
| 长度比 $\geq 0.9$ 子集胜率 | 64.7%（$n = 17$） | 67.9%（$n = 28$） |

两代实验构成一个有用的准实验对照：设计相同、模型不同，长度压缩的程度不同，胜率也随之不同，且方向一致。这与“长度是主要通道”的解释相容。当然，两代实验在任务措辞、评委数量、运行环境上也有差异，不能当作严格的剂量—反应证据，但它至少说明：把 v2 的 93% 当作“词对提示的一般性质”是危险的，它更像是“某个模型在某个预算下把答案压缩到 46% 之后的结果”。

## 5 讨论

### 5.1 为什么原创性上升、其余维度下降

一个自然的解释是：词对提供的是**远距概念并置**（如“缓存 · 沙漏”“日志 · 折线”），这类并置会诱导比喻与跨域映射，从而在“新颖性”上得分；但它不提供定义、机制、边界条件与可执行步骤，而这些恰是逻辑性、具体性与可操作性的来源。更关键的是，写词对消耗了预算，模型在剩余篇幅内只能给出压缩版方案——压缩首先删掉的就是细节与限定条件。于是出现一个看似矛盾、实则自洽的模式：答案“更有想法”，但“更不像一个能落地的方案”。任务 5（人格模型）之所以例外，是因为该任务本就以类比与维度组合为核心，压缩带来的损失较小，而联想带来的收益较大。

### 5.2 “灵感注入”叙事的三处反证

把本文的证据放在一起，可以对“词对提示能注入灵感”给出三条独立的反证。第一，**吸收率低**：词对中的词元只有 15%–17% 原样进入正文，八成以上的“灵感素材”没有被使用。第二，**预算是翻倍的**：词对条件平均多花 60%–100% 的 token，如果灵感真的有效，这笔投入应当换来更好的答案，而不是更短的答案。第三，**等长后效应大幅缩水**：在长度相近的子集上，胜率从 93% 降到 68%，等长点的条件效应只剩 $-0.82$。三条证据指向同一个结论：该提示的主要作用是改变输出的**预算分配**，而不是改变模型的**知识或联想**。

### 5.3 对提示设计的启示

如果确实想利用“远距联想”，本文的结果提示三种更合理的做法。其一，**把联想放在答案之后**：先让模型给出完整方案，再让它用词对做“二次发散”，最后合并修订；这样联想不占用首轮答案的预算。其二，**拆成两次调用**：一次生成词对，一次在独立上下文中作答，并把词对作为可选的参考材料而非必须前置的清单；这样可以用“是否引用”来度量收益。其三，**控制预算**：给对照组同样的 token 上限与“写到 X 字”的中性指令，使两条件的预算对称。无论采用哪种做法，都应当加入**中性前缀对照**——例如 200 行无意义文本或 200 组随机词——以区分“联想”与“仅仅多写了一段”。

如果研究目标确实是“验证联想”，更合适的做法是把因变量从“答案质量”换成“联想的使用”：统计词对词元在正文中的出现率与位置、要求模型显式标注“由第 $k$ 组词启发”，或由人工判断某个比喻是否真的来自词表。本文的覆盖率指标只是这种测量的最粗版本，但它已足以说明：在这批数据里，“灵感”不是主要通道。

### 5.4 对评测的启示

本文的分析也说明，开放生成任务的 A/B 评测需要三项最低限度的防护。第一，**报告并控制长度**：至少报告两条件的长度分布，并在长度匹配的子集上复算胜率；条件允许时应使用长度控制的胜率 [11]。第二，**按簇做推断**：同一提示下的多次采样不是独立样本，应按任务（或提示）做聚类 bootstrap，否则 $p$ 值会被高估十几个数量级。第三，**评委独立**：至少引入一个非生成家族的评委，并对每对做双向评审，报告 $\kappa$ 与位置效应；当边际分布极度失衡时，不应把高一致率当作可靠性证据。

### 5.5 成本—效果视角

如果把 token 视为成本、把评分视为收益，两个生成模型的账都算不过来：`deepseek-flash` 比对照多花约 4 160 个 token（+102%），整体分反而低 1.16；`deepseek-v4-pro` 多花约 3 670 个 token（+60%），整体分低 2.28。

即便只按唯一为正的原创性计算，`deepseek-flash` 上每提升 0.1 分也要多付约 720 个 token，而 `deepseek-v4-pro` 上原创性几乎不升，这笔投入等于全部沉没。作为对照，同一笔预算若用于多次采样再择优（best-of-$n$）或延长思考，按已有的测试时计算研究 [13]，通常能获得更可靠的收益。这提示我们：在预算受限的实际系统中，“先写词对”很难是划算的选择；它更像一种让输出“看起来更有想法”的风格化手段，而不是提升质量的工程手段。

## 6 效度威胁与局限

(1) **有效样本量小**。6 个任务就是 6 个簇，240 对并不提供 240 个独立观测。本文的所有区间都按任务聚类，因而比朴素区间宽得多；但也正因为簇只有 6 个，bootstrap 的覆盖率本身有限，结论应理解为“方向可靠、量级粗略”。

(2) **评委同家族**。生成与评审均来自 DeepSeek 家族，4 个格子中有 2 个是自评。虽然两位评委在胜负方向上高度一致，但自我偏好 [12] 与冗长偏差 [10] 可能同时放大了分差。缺少人类评

审是本文最大的外部效度缺口。

(3) **清洗与生成同模型**。清洗由生成同款模型完成，它可能系统性地删掉“具体细节”而保留“框架性表述”，这会让具体性维度的下降部分归因于清洗而非词对条件。清洗长度比的中位数 0.99 说明整体删改不大，但长尾样本（最小 0.635）提示个别样本受影响明显。

(4) **中介分析的固有局限**。长度是处理后变量，控制它得到的是反事实估计而非无偏因果效应；若存在同时影响长度与评分的未观测因素，−0.82 的截距仍可能有偏。

(5) **测量口径**。本文以字符数作为长度，中文的 token/字符比在不同模型间并不相同（本数据中分别约为 1.97 与 2.52），因此跨模型的长度比较应谨慎；若以 token 计，长度差会更大。

(6) **任务范围**。六个任务均为开放式创意任务，结论不应外推到数学、代码、事实问答等有客观判据的任务；在这些任务上，前置生成可能通过“草稿”机制带来真实收益。

(7) **处理的操作化**。词对条件不只是“多写 200 组词”，它还包含一句明确的指令“从这些词获得灵感”。模型可能因此切换到联想式、比喻式的写作风格，而这一风格变化与“词对内容是否被使用”是两件事。覆盖率分析说明内容层面的使用很少，但无法排除“指令措辞导致风格变化”这一通道；要分离两者，需要“写 200 组词但不许引用”与“写 200 行中性文本”两个额外对照。

## 7 可复现性

本文的全部数字都可以从仓库的原始 JSONL 重新计算，不依赖任何汇总文件。复现步骤为：克隆仓库并切换到 `v2-deepseek` 分支；运行生成侧统计脚本，按 `(task_id, condition, run)` 去重后得到 120 条生成；运行盲评统计脚本，按 `(task_id, run)` 去重后得到 240 对；随后依次计算胜负、五维、长度分层、聚类 bootstrap 与回归。本文使用的分析脚本、中间结果（`results.json`、`pairs.csv`、`features.json`）与作图代码随文提供。

从可复现性的角度，原仓库有两处值得改进：其一，生成记录缺少 `pair_count` 字段，处理剂量只能靠事后解析（且存在每行 1 组、每行 10 组、三位补零等多种格式，按行计数会严重低估）；其二，记录缺少 `finish_reason` 与实际 `max_tokens`，使得“是否被截断”无法从数据自证。建议在后续版本中补齐这两个字段，并把评委的 A/B 顺序改为分层平衡而非哈希。

## 8 结论

本文对一个公开的“词对提示”实验做了独立复算与再分析。结论有三点。第一，**效应方向明确**：在 6 个开放式任务、2 个生成模型、2 个评委、240 对盲评中，直接回答以 93.3% 的胜率压倒性胜出，唯一提升的维度是原创性（+0.31）。第二，**效应机制主要是预算重分配**：词对条件多花约一倍 token，却把正文压缩到 46%–73%；词对中的词元只有 15%–17% 进入正文；控制长度后，条件效应从 −1.72 收窄到 −0.82，在长度相近的子集上胜率降至 68%。第三，**“灵感注入”的说法缺乏支持**：如果词对真的提供了灵感，我们应当看到更高的词元吸收率、更长的正文，以及等长条件下仍然明显的质量优势；三者都没有出现。

据此，我们认为更准确的表述是：在答案前要求模型输出大量词对，会挤占答案的生成预算，使回答变短、细节与结构减少，评审据此给出更低的分数；其中约一半的差距可由长度解释，原

创性有轻微提升且依赖模型与任务。这一结论对提示设计的意义是：不要用与答案共享预算的前置生成去“激发”模型；若确实需要发散，应把发散放在答案之后或独立的调用中，并用等预算、长度匹配与中性前缀对照来验证收益。

## 参考文献

[1] Meyer D E, Schvaneveldt R W. Facilitation in recognizing pairs of words: evidence of a dependence between retrieval operations[J]. Journal of Experimental Psychology, 1971, 90(2): 227–234.

[2] Wei J, Wang X, Schuurmans D, et al. Chain-of-thought prompting elicits reasoning in large language models[C]//Advances in Neural Information Processing Systems (NeurIPS). 2022.

[3] Kojima T, Gu S S, Reid M, et al. Large language models are zero-shot reasoners[C]//Advances in Neural Information Processing Systems (NeurIPS). 2022.

[4] Wang X, Wei J, Schuurmans D, et al. Self-consistency improves chain of thought reasoning in language models[C]//International Conference on Learning Representations (ICLR). 2023.

[5] Sclar M, Choi Y, Tsvetkov Y, et al. Quantifying language models' sensitivity to spurious features in prompt design or: how I learned to start worrying about prompt formatting[C]//International Conference on Learning Representations (ICLR). 2024.

[6] Webson A, Pavlick E. Do prompt-based models really understand the meaning of their prompts?[C]// Proceedings of the 2022 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL). 2022.

[7] Mizrahi M, Kaplan G, Malkin D, et al. State of what art? A call for multi-prompt LLM evaluation[J]. Transactions of the Association for Computational Linguistics (TACL), 2024.

[8] Zheng L, Chiang W L, Sheng Y, et al. Judging LLM-as-a-judge with MT-Bench and Chatbot Arena[C]// Advances in Neural Information Processing Systems (NeurIPS), Datasets and Benchmarks Track. 2023.

[9] Wang P, Li L, Chen L, et al. Large language models are not fair evaluators[C]//Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (ACL). 2024.

[10] Saito K, Wachi A, Wataoka K, et al. Verbosity bias in preference labeling by large language models[EB/OL]. arXiv:2310.10076, 2023.

[11] Dubois Y, Galambosi B, Liang P, et al. Length-controlled AlpacaEval: a simple way to debias automatic evaluators[EB/OL]. arXiv:2404.04475, 2024.

[12] Panickssery A, Bowman S R, Feng S. LLM evaluators recognize and favor their own generations[C]// Advances in Neural Information Processing Systems (NeurIPS). 2024.

[13] Snell C, Lee J, Xu K, et al. Scaling LLM test-time compute optimally can be more effective than scaling model parameters[C]//International Conference on Learning Representations (ICLR). 2025.

[14] Jin M, Yu Q, Huang H, et al. The impact of reasoning step length on large language models[C]// Findings of the Association for Computational Linguistics: ACL 2024. 2024.

## 附录：数据字段与复算命令

盲评记录的关键字段包括：gen_model、judge_model、task_id、run、swap、A_source、B_source、baseline_content、cleaned_content、A_scores、B_scores、winner_label 与 reason。由于 content 字段保存的是评委实际看到的全文，本文的长度测量无需再拼接提示模板。复算时按（task_id，run）取最新记录即可得到 240 对；按 A_source 把 A_scores/B_scores 还原到条件后，即可复现表 3 与表 4。

数据来源：https://gitee.com/qwe12345678/jkdsfn（分支 v2-deepseek，提交 88e0b9a）。本文分析脚本：01_analyze.py（复算与统计）、02_features.py（文本特征）、03_figures.py（作图）。

复算环境为 Python 3.11、NumPy 2.4、SciPy 1.17、Matplotlib 3.11，排版为 XeLaTeX + ctex。从零复现的命令如下（脚本位于项目根目录的 scripts/）：

```
git clone -b v2-deepseek \
  https://gitee.com/qwe12345678/jkdsfn.git repo_jkdsfn
python3 scripts/01_analyze.py    # 胜负、五维、长度分层、聚类 bootstrap、回归
python3 scripts/02_features.py   # 文本特征、评审理由词频、v1 跨代复现
python3 scripts/03_figures.py    # 生成图 1--图 4 的 PDF 矢量图
xelatex paper.tex && xelatex paper.tex   # 生成 paper.pdf
```

其中 01_analyze.py 输出 out/results.json 与 out/pairs.csv，02_features.py 输出 out/features.json；正文中的每个数字都可以在这三个文件中找到对应字段。若只需核对主结果，读取 8 个 JSONL 并复现表 3 即可，无需运行任何统计模型。