先写 200 组词对能提升回答质量吗？

——对一项 240 对盲评实验的独立复算与再分析

作者姓名[1]

[1] 单位名称，城市邮编

email@example.com

摘要

在问题前加一句“先输出 200 组两词短语，再从中获得灵感”，是中文大模型社区流行的一种“灵感注入”式提示。本文对一个公开实验的 240 对盲评数据做独立复算与再分析。该实验覆盖 6 个开放式任务、2 个生成模型、2 个评委，每个“任务 × 条件”单元重复 10 次。复算显示：直接回答在 224/240 对中获胜（93.3%，任务聚类 bootstrap 95% 置信区间 $[86.7\%, 97.1\%]$）；五个维度中仅原创性略升（+0.31），逻辑性、具体性、可操作性与整体质量分别下降 1.54、2.08、2.32 与 1.72 分。进一步分析表明，这一差距与输出长度高度相关（Spearman $\rho = 0.585$）：词对条件的正文被压缩到对照的 73%（`deepseek-flash`）与 46%（`deepseek-v4-pro`），而输出 token 数反而增至 2.02 倍与 1.60 倍；在长度比不低于 0.9 的子集（$n = 28$）上，胜率降至 67.9%；将长度差纳入回归后，等长处的条件效应由 -1.72 收窄至 -0.82（95% CI $[-1.38, -0.26]$）。机制上，词对块中的词元只有 16.9% 与 15.1% 原样出现在正文中。本文认为，该提示的主要后果是输出预算的重新分配与正文压缩，而非“从词中获得灵感”；据此提出等 token 预算、长度匹配与中性前缀对照三项设计修正。

1 引言

在中文大模型社区里流传着一种被称作“词对提示”的写法：在正式问题之前，要求模型先输出 200 组两词短语（例如“晨光 · 缓存”“指纹 · 钥匙”“日志 · 折线”），再“从这些词中获得灵感”作答。支持者的直觉是，随机的远距联想能把回答推离陈词滥调，产生更具原创性的方案。这个直觉并非空穴来风：心理学中的语义启动（semantic priming）表明，先前的词汇加工会改变后续概念的通达性 [**?**]；而在语言模型上，“先写出推理过程再给答案”也确实能在多步推理任务上带来稳定增益 [**?**, **?**, **?**]。但两者之间有一个关

图 1 分任务胜负分布（每任务 40 对）。任务 5“人格模型”是唯一出现较多词对胜场的任务。

键差别：思维链的前置文本与答案共享同一套推理结构，其每一个中间步骤都被后续步骤使用；词对与答案之间却只有极弱的语义关联，前置生成主要是消耗同一份输出预算。

这类“前置生成”提示究竟带来什么，目前缺少可复核的证据。已有的提示敏感性研究反复表明，提示的表面形式——分隔符、格式、示例顺序、甚至与语义无关的模板——都可能显著改变模型表现 [**?**, **?**, **?**], 因此仅凭少量成功案例很难判断一个提示技巧的真实效应。与此同时，用大语言模型充当评委（LLM-as-a-judge）虽然与人类偏好高度相关 [**?**]，却已知存在位置偏差 [**?**]、冗长偏差 [**?**, **?**] 与自我偏好 [**?**]。当评测对象是“更短还是更长”这类系统性差异时，评委的打分很容易把篇幅差异误读为质量差异。

本文不提出新的提示方法，而是对一个公开实验[1]做独立复算与再分析。该实验的原始结论是“词对提示显著降低了回答质量”。我们复算后确认了胜负计数与五维均分，但认为这一表述把一个“更短、更少细节”的差异包装成了“质量差异”，因而既高估了效应的普遍性，也错过了更有价值的机制问题。本文的贡献是：

(1) **独立复算**. 从原始 JSONL 重新计算全部胜负、五维评分、评委一致性与位置效应，与仓库自报数字逐项对齐，并给出任务聚类的置信区间，纠正了把 240 对当作 240 个独立样本导致的显著性高估（朴素二项检验 $p \approx 4 \times 10^{-48}$，按任务聚类后 95% CI 为 $[86.7\%, 97.1\%]$）。

(2) **长度中介的定量证据**. 通过分层、子集与含任务固定效应的回归，估计出长度差可解

[1]数据与代码：`https://gitee.com/qwe12345678/jkdsfn`（提交 `88e0b9a`，原 `v2-deepseek` 分支）。

释约一半的评分差距；在长度相等处，条件效应由 -1.72 收窄至 -0.82.

(3) **机制证据**. 给出 “预算重分配” 的直接测量：词对条件多花 60%–102% 的 token，却把正文压缩到 46%–73%；同时词对词元在正文中的原样复现率仅 15%–17%，说明 “灵感” 在字面上几乎没有兑现。

(4) **设计修正**. 据此提出等 token 预算、长度匹配与中性前缀对照三项可操作的实验设计，并给出一份针对此类 “前置生成” 提示的效度清单。