先写 200 组词对能提升回答质量吗？

——对一项 240 对盲评实验的独立复算与再分析

作者姓名[1]

[1] 单位名称，城市邮编

email@example.com

摘要

在问题前加一句“先输出 200 组两词短语，再从中获得灵感”，是中文大模型社区流行的一种“灵感注入”式提示。本文对一个公开实验的 240 对盲评数据做独立复算与再分析。该实验覆盖 6 个开放式任务、2 个生成模型、2 个评委，每个“任务 × 条件”单元重复 10 次。复算显示：直接回答在 224/240 对中获胜（93.3%，任务聚类 bootstrap 95% 置信区间 $[86.7\%, 97.1\%]$）；五个维度中仅原创性略升（+0.31），逻辑性、具体性、可操作性与整体质量分别下降 1.54、2.08、2.32 与 1.72 分。进一步分析表明，这一差距与输出长度高度相关（Spearman $\rho = 0.585$）：词对条件的正文被压缩到对照的 73%（`deepseek-flash`）与 46%（`deepseek-v4-pro`），而输出 token 数反而增至 2.02 倍与 1.60 倍；在长度比不低于 0.9 的子集（$n = 28$）上，胜率降至 67.9%；将长度差纳入回归后，等长处的条件效应由 -1.72 收窄至 -0.82（95% CI $[-1.38, -0.26]$）。机制上，词对块中的词元只有 16.9% 与 15.1% 原样出现在正文中。本文认为，该提示的主要后果是输出预算的重新分配与正文压缩，而非“从词中获得灵感”；据此提出等 token 预算、长度匹配与中性前缀对照三项设计修正。

1 引言

在中文大模型社区里流传着一种被称作“词对提示”的写法：在正式问题之前，要求模型先输出 200 组两词短语（例如“晨光 · 缓存”“指纹 · 钥匙”“日志 · 折线”），再“从这些词中获得灵感”作答。

2 相关工作

文字 here.

图 1　分任务胜负分布（每任务 40 对）。任务 5“人格模型”是唯一出现较多词对胜场的任务。